Московский государственный университет имени М.В. Ломоносова

Направление 38.03.01 Экономика

Программа «Национальная экономика»

Прогнозирование рисков банковского кредитования с использованием технологий искусственного интеллекта

Выпускная квалификационная работа

Студент

Касенова Асем Ардаковна

Научный руководитель:

к.э.н., к.ф.-м.н., к.ю.н., доцент

Сидоренко Владимир Николаевич

Астана

2026

ОГЛАВЛЕНИЕ

Введение 3

Глава 1. Тестирование алгоритмов машинного и глубокого обучения на больших данных по кредитному скорингу 6

1.1 Подбор гиперпараметров для алгоритмов машинного обучения при оценке возврата кредита 6

1.1.1 Деревья решений 7

1.1.2 Случайный лес 10

1.1.3 Градиентный бустинг 13

1.1.4 Нейронная сеть 14

1.2 Ограничения и возможности моделей 17

Введение

Актуальность темы исследования. В условиях технологического развития и цифровизации финансового сектора искусственный интеллект (далее ИИ) становится ключевым инструментом обработки больших данных и повышения точности управленческих решений. Для банковского сектора одной из ключевых задач является оценка кредитоспособности заемщиков, определяющая устойчивость кредитного портфеля и уровень кредитных рисков банков.

Актуальность исследования обусловлена ростом закредитованности населения Казахстана на фоне снижения реальных доходов. На начало 2026 г. общая долговая нагрузка населения составила около 27,8 трлн тенге[1], при этом реальные доходы граждан снижаются – индекс реальной заработной платы составил -0,4%[2]. Банки продолжают наращивать кредитные портфели, а население – брать займы под высокие проценты (до 20% годовых[3]) для покрытия текущих расходов. Как следствие, объем необслуживаемых кредитов с просрочкой более трех месяцев достиг 1,65 трлн тенге[4], причем доля таких кредитов увеличивается в 2 раза быстрее, чем сам кредитный портфель. В связи с этим совершенствование кредитного скоринга, в том числе на основе ИИ, позволит снизить риски для банков и защитить заемщиков от чрезмерной долговой нагрузки.

Степень разработанности темы исследования. Современное понимание искусственного интеллекта сформировалось в середине XX века. Так, впервые в 1950 г. А. Тьюринг[5] предложил критерий оценки «машинного интеллекта» (тест Тьюринга), а в 1956 г. на семинаре в Дартмунском колледже был введен термин «искусственный интеллект» Д. Мак-Карти[6]. Однако прикладное развитие ИИ в финансовой сфере стало возможным в начале 2000-х, когда рост вычислительных мощностей и распространение методов машинного и глубокого обучения позволили анализировать большие массивы неоднородных данных. В банковской практике это выразилось в переходе от традиционных статистических скоринговых моделей к ИИ-подходам, способным учитывать сложные нелинейные зависимости и использовать альтернативные данные для оценки

[1] Ловушка в 20%: почему казахстанцы продолжают кредитоваться при падающих доходах [Электронный ресурс] / Информационный портал РК. URL: https://www.zakon.kz/finansy/6505800-lovushka-v-20-pochemu-kazakhstantsy-prodolzhayut-kreditovatsya-pri-padayushchikh-dokhodakh.html (дата обращения: 3.03.2026).

[2] см. Там же.

[3] Казахстанцев ждет долговая усталость в 2026 году: экономист озвучил опасения [Электронный ресурс] / Общественно-политическое издание Центральной Азии. URL: https://kz.kursiv.media/2026-01-27/svan-kazahstancy-prodolzhayut-popolnyat-depozity-i-brat-novye-kredity-nesmotrya-na-stavku/ (дата обращения: 3.03.2026).

[4] Забытые долги казахстанцев перед банками выросли в полтора раза за год [Электронный ресурс] / Общественно-политическое издание Центральной Азии. URL: https://kz.kursiv.media/2026-03-02/fvfv-zabytyye-dolgi-kazakhstantsev-pered-bankami-vyrosli-v-poltora-raza-za-god/?utm_source=kursiv&utm_campaign=read_more (дата обращения: 3.03.2026).

[5] А. Тьюринг (1912-1954 гг.) – английский математик, логик, криптограф, основоположник ИИ.

[6] Д. Мак-Карти (1927-2011 гг.) – американский ученый, автор термина «искусственный интеллект», лауреат премии Тьюринга за исследования в области ИИ.

вероятности дефолта.

В работах зарубежных исследователей Addy W.A., Ajayi-Nifise A.O., Bello B.G., Tula S.T., Odeyemi O., Falaiye T., Bari H., Kothandapani H.P., Arora G., Bathla R., Nuka T.F., Ogunola A.A., Omotosho M.A. рассматривается возможность использования алгоритмов машинного обучения в прогнозировании кредитного риска. В исследованиях Vakrani D.S., Padhye P.S., Gupta S.K., Roy J.K., Nerlekar V.S., Parashar N. проводится сравнительный анализ алгоритмов с целью повышения точности оценки кредитоспособности заемщика. В российских и казахстанских работах Балаян В.С., Городецкой О.Ю., Гобаревой Я.Л., Гозгешевой Э.А., Даркенбаева Д.К., Зиятбековой Г.З., Алтыбай А., Мекебаева Н.О., Жамангарина Д.С. исследуется применение алгоритмов машинного обучения для совершенствования систем кредитного скоринга, повышения эффективности управления кредитными рисками, а также сравниваются различные модели машинного обучения и анализируются их метрики качества.

Анализ указанных работ показывает, что большинство исследователей сосредоточены на выборе и сравнении алгоритмов машинного обучения, а также на повышении точности моделей кредитного скоринга, тогда как качеству исходных данных и структуре обучающей выборки уделяется меньше внимания. В существующих работах практически не рассматривается проблема наличия аномальных заемщиков, поведение которых схоже с поведением платежеспособных клиентов, но характеризуется систематическими задержками платежей. В связи с этим в данной работе особое внимание уделяется выявлению аномальных клиентов на основе анализа их платежной истории, а также оценке влияния переклассификации таких наблюдений на качество моделей машинного и глубокого обучения в задачах кредитного скоринга с целью снижения кредитных рисков.

Цель и задачи исследования. **Цель** – разработать метод прогнозирования дефолта заемщика банка при выдаче кредита на основе методов машинного и глубокого обучения. Для достижения поставленной цели были определены следующие задачи:

1. Провести анализ данных о заемщиках и выявить их особенности платежного поведения, которые влияют на вероятность возникновения дефолта.
2. Исследовать существующие методы оценки кредитоспособности заемщиков и возможности применения алгоритмов машинного и глубокого обучения в задаче кредитного скоринга.
3. Выявить аномальные наблюдения в платежной истории заемщиков и оценить их влияние на результаты прогнозирования моделей кредитного скоринга.
4. Построить и протестировать модели машинного и глубокого обучения для прогнозирования вероятности дефолта заемщиков.
5. Оценить качество полученных моделей и определить их практическую применимость для снижения кредитных рисков банков.

Объект и предмет исследования. **Объектом** исследования является выдан-

ный кредит банком и связанное с ним наступление либо отсутствие дефолта по выданным кредитам. **Предметом** исследования является кредитный скоринг для оценки риска невозврата кредита.

Методы исследования. Для достижения целей и решения поставленных задач использовались методы машинного и глубокого обучения, статистического анализа, предобработки и преобразования данных, выявления аномальных наблюдений, а также методы оценки качества и сравнительного анализа моделей прогнозирования дефолта заемщиков.

Научная новизна исследования заключается в том, что в работе впервые предложено определение аномального клиента на основе анализа его платежной истории. Математически обоснована принадлежность таких клиентов к классу дефолтных заемщиков, а также исследовано влияние переклассификации данных наблюдений на качество моделей машинного и глубокого обучения при прогнозировании дефолта в задаче кредитного скоринга.

Информационная база исследования. Информационной базой являются платформы: Open Data Science (ODS.AI), github, stackoverflow, а также нормативно-правовая база, информационные порталы, научные статьи и монографии.

Публикации автора по теме исследования. По результатам исследований работа удостоилась диплома II степени на тему «Определение кредитного скоринга заемщиков банка на основе технологии машинного обучения» в конкурсе на лучшую научно-исследовательскую работу студентов и магистрантов Казахстанского филиала МГУ имени М.В. Ломоносова на 25-летие филиала.

Публикация тезисов на тему «Прогнозирование дефолта заемщиков банка с использованием нейронной сети».

Структура и объем работы. Выпускная квалификационная работа состоит из 50 страниц, X таблиц, Y рисунков и Z приложений. Работа включает введение, три главы, заключение и список литературы.

ГЛАВА 1. ТЕСТИРОВАНИЕ АЛГОРИТМОВ МАШИННОГО И ГЛУБОКОГО ОБУЧЕНИЯ НА БОЛЬШИХ ДАННЫХ ПО КРЕДИТНОМУ СКОРИНГУ

В предыдущей главе было выяснено, что алгоритмы градиентного бустинга и нейронных сетей не имеют эффектов переобучения и недообучения. В случае градиентного бустинга используются гиперпараметры по умолчанию, результаты метрик которых не ниже метрик других алгоритмов. Это означает, что не требуется поиск гиперпараметров для данного алгоритма и можно остановиться на гиперпараметрах по умолчанию. Идентичная ситуация возникает у нейронной сети с отличием в том, что у нее метрики точности немного хуже, чем у алгоритма градиентного бустинга. В этой главе будут подобраны гиперпараметры для алгоритмов деревьев решений и случайного леса, поскольку они обладают эффектом переобучения. Основным инструментом для поиска оптимальных гиперпараметров используются инструменты *GridSearchCV*[1] и *RandomizedSearchCV*[2]. Также в конце главы будут проанализированы прибыль и убыток банка на основании предсказаний четырех рассмотренных алгоритмов.

1.1 Подбор гиперпараметров для алгоритмов машинного обучения при оценке возврата кредита

Гиперпараметры – это такие параметры модели, которые задаются до начала работы модели. Правильно подобранные параметры позволяют улучшить качество предсказаний моделей. Каждому алгоритму МО присуще собственные наборы гиперпараметров, которые будут рассматриваться ниже. Существуют два метода подбора гиперпараметров:

1. *GridSearchCV* – метод подбора оптимальных гиперпараметров для модели с помощью перебора всех возможных комбинаций из заданного набора, что является ресурсозатратным способом.
2. *RandomizedSearchCV* – метод, позволяющий выбирать количество случайных комбинаций из заданного набора гиперпараметров. Является наиболее эффективным методом по времени при работе с большими данными.

[1] GridSearchCV [Электронный ресурс] / Python-библиотека для машинного обучения. URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html (дата обращения: 25.11.2025).

[2] RandomizedSearchCV [Электронный ресурс] / Python-библиотека для машинного обучения. URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.RandomizedSearchCV.html (дата обращения: 25.11.2025).

1.1.1 Деревья решений

Для алгоритма классификации решающих деревьев (*Decision Tree Classifier*) основными гиперпараметрами являются:

1. *criterion* – критерий качества разбиения, определяющая показатель, по которому алгоритм лучше классифицирует клиентов.
   a) *gini* – индекс Джини[3], измеряющий неоднородность двух классов (0 и 1) внутри узла. Если индекс равен 0, значит в узле содержатся объекты одного класса. Чем индекс ближе к 0, тем лучше алгоритм определяет класс клиента. Индекс Джини в алгоритме *Decision Tree* используется по умолчанию, поскольку быстрее вычисляется;
   b) *entropy* – энтропия Шеннона[4], измеряющий степень смешанности классов. Высокая энтропия свидетельствует о высокой неоднородности классов, чем ниже энтропия, тем узел более однородный. Алгоритм выбирает разбиения с наиболее низкой энтропией, т.е. содержатся большинство объектов одного класса;
   c) *log_loss* – логарифмическая функция потерь. В данном случае алгоритм не просто выбирает класс, а оценивает их вероятности. За каждый неверный прогноз вводит штраф.
2. *splitter* – параметр, задающий способ разбиения каждого узла дерева решений.
   a) *best* – алгоритм последовательно перебирает все возможные признаки и пороги, которые лучше всего разделяют клиентов по целевой переменной. При данном параметре требуется больше времени на обучение.
   b) *random* – в каждом узле дерева рассматривается случайная часть разбиения, среди которых выбирается лучшее значение. За счет этого модель быстрее обучается, но качество разбиений может быть немного хуже, чем при *best*.
3. *max_depth* – максимальная глубина дерева решений. Чем больше глубина, тем длиннее цепочка вопросов, чтобы выдать прогноз по клиенту. При небольших значениях алгоритм делает мало разбиений и недообучается, т.е. плохо объясняет данные и дает невысокую точность на обучающей и тестовой выборках. При высоких значениях алгоритм, наоборот, переобучается, запоминает все особенности обучающей выборки, но плохо классифицирует клиентов на тестовых данных.
4. *min_samples_split* – параметр задает минимальное число наблюдений в узле, при котором возможно следующее разбиение на два дочерних. Если в узле наблюдений меньше заданного порога, то дальнейшее разбиение не выполняется, и узел становится конечным.

[3]Джини К. (1884-1965 гг.) – итальянский статистик, экономист, социолог и демограф.
[4]Шеннон К.Э. (1916-2001 гг.) – американский инженер, криптоаналитик и математик, заложил основы теории информации.

5. $min_samples_leaf$ – параметр с минимальным заданным количеством наблюдений после разбиения в каждом узле, что позволяет дереву не создавать слишком маленькие группы клиентов и служит инструментов против переобучения алгоритма.
6. $max_features$ – параметр задает случайное количество признаков, среди которых алгоритм ищет оптимальное разделение.
   a) $sqrt$ – в каждой вершине выбирается количество признаков, равное квадратному корню из общего числа признаков.
   b) $log2$ – число признаков, равное двоичному логарифму от их общего количества.
7. $random_state = 42$ – произвольное число[5], задаваемое программе, чтобы при каждом запуске программы конечный результат оставался неизменным.

В таблице 1 указаны найденные гиперпараметры на 3 000 000 клиентов алгоритма деревья решений двумя методами $GridSearchCV$ и $RandomizedSearchCV$.

Таблица 1 – Выбор гиперпараметров для алгоритма $Decision\ Tree$ по двум методам

	GridSearchCV	RandomizedSearchCV
criterion	entropy	log_loss
splitter	best	best
max_depth	20	20
max_features	`sqrt`	`sqrt`
min_samples_leaf	20	15
min_samples_split	10	15
random_state	42	42

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

С помощью найденных гиперпараметров алгоритм решающих деревьев продемонстрировал следующие результаты (см. Таблицу 2, см. Таблицу 3). Из таблицы 2 видно, что после подбора гиперпараметров методом $GridSearchCV$ алгоритм дерева решений показал высокое качество классификации на обучающей и тестовой выборках. Высокие значения $precision$ указывают на то, что модель редко ошибочно определяет метку класса клиентов. Также значения $recall$ демонстрируют, что модель хорошо выявляет недефолтных и дефолтных заемщиков. Значения $f1 - score$ подтверждают сбалансированность между точностью и полнотой метрик. Метрика $accuracy$, равная 0.98, указывает на высокую долю верно классифицированных наблюдений, а $ROC - AUC$ на уровне 0.98–0.99 демонстрирует высокую способность модели разделять клиентов на два класса. Близость результатов метрик позволяет сделать вывод об отсутствии выраженного переобучения модели.

[5]Почему именно «42» - широко известное и запоминающееся значение по умолчанию среди исследователей. Это ответ на главный вопрос жизни, Вселенной и всего сущего в романе Дугласа Адамса «Автостопом по Галактике».

Таблица 2 – Метрики точности алгоритма Decision Tree с использованием *GridSearchCV*

Алгоритм – Деревья решений						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.98	0.98	0.99	1438473
1	0.94	1.00	0.97			811527
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	478610
1	0.95	1.00	0.97			271390

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Для более наглядной интерпретации полученных результатов представлена матрица ошибок (см. Рисунок 1). На обучающей выборке модель допустила 78 ошибок при классификации недефолтных клиентов и 44960 ошибок при классификации дефолтных клиентов. На тестовой выборке соответствующие значения составили 34 и 14912 ошибок. Снижение неверных предсказаний на тестовой выборке объясняется меньшим объемом этой выборки. Можно заметить, что структура ошибок на обучающей и тестовой выборках остается близкой, указывая на сохранение качества классификации на тестовых данных и отсутствии выраженного переобучения.

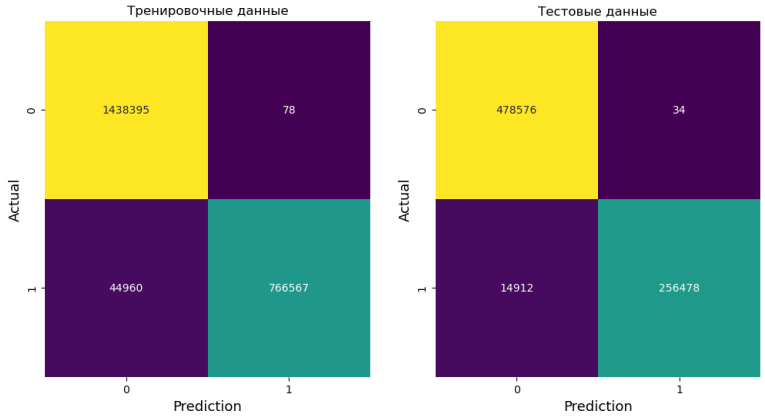

Рисунок 1 – Результаты подбора гиперпараметров с помощью *GridSearchCV*

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Значения метрик, подобранные методом *RandomizedSearchCV* (см. Таблицу 2), остаются высокими и близкими к результатам, полученными методом *GridSearchCV*, поэтому основное внимание уделяется сравнению матриц ошибок.

Таблица 3 – Метрики точности алгоритма Decision Tree с использованием *RandomizedSearchCV*

Алгоритм – Деревья решений						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.98	0.98	0.98	1438473
1	0.94	1.00	0.97			811527
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	478610
1	0.94	1.00	0.97			271390

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Из рисунка 2 видно, что в данном случае модель допускает примерно в 12 раз ошибок как на обучающей, так и на тестовой выборках. Сравнив результаты ошибочных классификаций, выбор делается в пользу гиперпараметров, подобранных методом *GridSearchCV*.

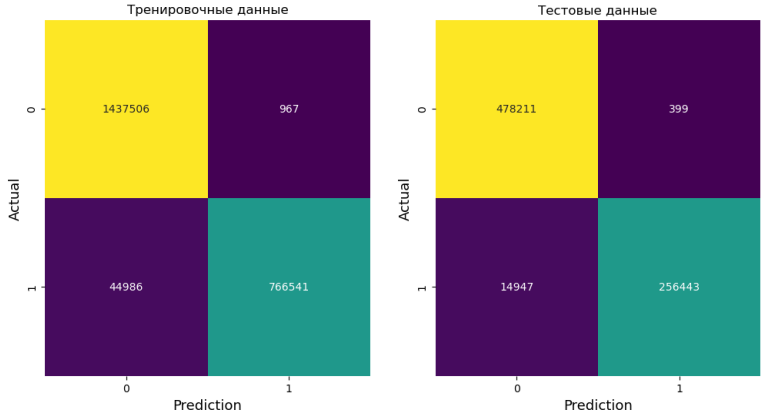

Рисунок 2 – Результаты подбора гиперпараметров с помощью *RandomizedSearchCV*

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

1.1.2 Случайный лес

Случайный лес (*Random Forest*) является модификацией алгоритма деревья решений. По этой причине данные алгоритмы имеют схожие гиперпараметры, кроме $n_estimators$, где $n_estimators$ – это число деревьев в алгоритме случайного леса.

Таблица 4 – Выбор гиперпараметров для алгоритма *Random Forest* по двум методам

	GridSearchCV	RandomizedSearchCV
n_estimators	60	80
criterion	gini	log_loss
max_depth	20	20
max_features	`sqrt`	`log2`
min_samples_leaf	10	15
min_samples_split	30	20
random_state	42	42

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Из таблицы 5 видно, что после подбора гиперпараметров с помощью *GridSearchCV* алгоритм показал высокое качество классификации на обеих выборках. Высокие значения метрик *precision*, *recall*, $f1 - score$ свидетельствуют о хорошем распозновании недефолтных и дефолтных клиентов. Значения *accuracy* и $ROC - AUC$ также показывают хорошую разделяющую способность модели. Вместе с тем для класса 1 на обучающей выборке метрики немного выше, чем на тестовой, что указывает на небольшой эффект переобучения. Однако различия не являются существенными, поэтому модель сохраняет хорошую предсказательную способность.

Таблица 5 – Метрики точности с использованием *GridSearchCV*

Алгоритм – Случайный лес						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.99	0.99	0.99	0.98	1438473
1	1.00	0.98	0.99			811527
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	478610
1	0.95	1.00	0.97			271390

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Матрица ошибок (см. Рисунок 3) подтверждает результаты таблицы 5. Большинство наблюдений на обеих выборках верно классифицировано, а число ошибок остается примерно на прежнем уровне, что и у алгоритма *Decision Tree*. При этом относительная доля ошибок по обоим классам остается близкой, что указывает на хорошую устойчивость модели при классификации наблюдений.

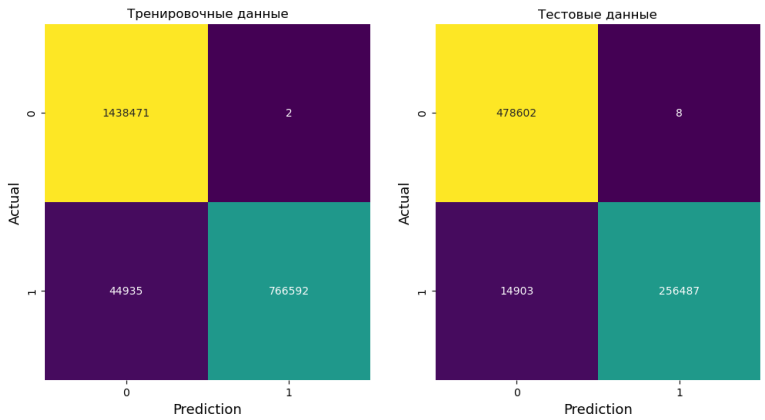

Рисунок 3 – Результаты подбора гиперпараметров с помощью *GridSearchCV*

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Из таблицы 6 видно, что алгоритм с гиперпараметрами, подобранными методом *RandomizedSearchCV*, сохраняет высокое качество классификации на обеих выборках. Однако по отдельным метрикам для класса 1 результаты немного ниже по сравнению с *GridSearchCV*.

Таблица 6 – Метрики точности с использованием *RandomizedSearchCV*

Алгоритм – Случайный лес						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	1.00	0.97	0.98	0.98	0.99	1438473
1	0.94	1.00	0.97			811527
Тестовая выборка						
0	1.00	0.97	0.98	0.98	0.98	478610
1	0.95	1.00	0.97			271390

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Матрица ошибок (см. Рисунок 4) показывает, что модель с гиперпараметрами, подобранными методом *RandomizedSearchCV*, допускает больше ошибок по классу 0 по сравнению с вариантом *GridSearchCV*, при этом число ошибок по классу 1 немного ниже. Тем не менее общее число ошибок выше, чем при *GridSearchCV*, поэтому в данном случае целесообразно выбрать гиперпараметры, найденные с помощью *GridSearchCV*.

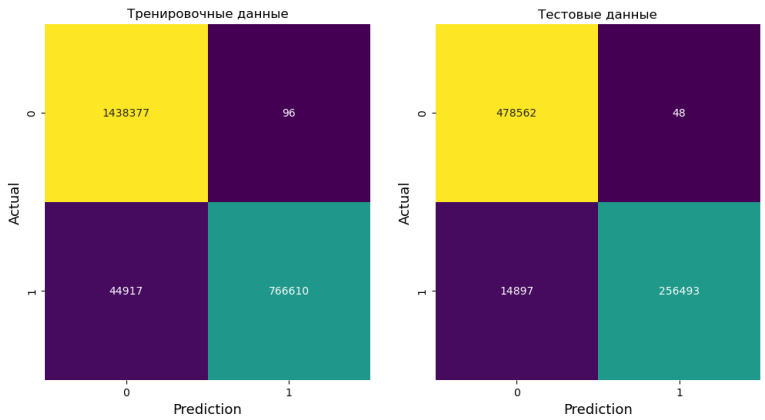

Рисунок 4 – Результаты подбора гиперпараметров с помощью *RandomizedSearchCV*

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

1.1.3 Градиентный бустинг

В данной работе для алгоритма градиентного бустинга (*Gradient Boosting*) использовались гиперпараметры по умолчанию. В отличие от алгоритмов *Decision Tree* и *Random Forest*, для которых гиперпараметры подбирались методами *GridSearchCV* и *RandomizedSearchCV*, базовая настройка модели обеспечила высокое качество классификации. В связи с этим дополнительный подбор гиперпараметров не проводился, и далее рассматриваются полученные метрики точности модели.

Метрики точности (см. Таблицу 7) свидетельствуют о высоком качестве классификации данного алгоритма. Значения метрик *precision*, *recall*, $f1 - score$ по обоим классам остаются высокими на двух выборках. Показатели *accuracy* и $ROC - AUC$ также подтверждают хорошую разделяющую способность модели. При этом выраженный эффект переобучения не наблюдается, поскольку значения метрик на обучающей и тестовой выборках практически совпадают.

Таблица 7 – Метрики точности с гиперпараметрами по умолчанию алгоритма *Gradient Boosting*

Алгоритм – Градиентный бустинг						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	0.99	0.97	0.98	0.98	0.99	1438473
1	0.95	0.99	0.97			811527
Тестовая выборка						
0	0.99	0.97	0.98	0.98	0.98	478610
1	0.95	0.99	0.97			271390

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Матрица ошибок (см. Рисунок 5)подтверждает результаты метрик таблицы 7. Большинство наблюдений на тренировочной и тестовой выборке верно классифицировано, однако число ошибок в данном случае больше, чем у алгоритмов дерева решений и случайного леса. На обучающей выборке модель неверно отнесла 7 347 недефолтных клиентов к классу 1 и 44 468 дефолтных клиентов к классу 0, а на тестовой выборке 2 507 и 14 751 соответственно. Структура ошибок остается близкой, что также указывает на отсутствие выраженного переобучения. Таким образом, градиентный бустинг показывает высокое качество классификации наблюдений, но уступает по числу ошибок ранее рассмотренным моделям.

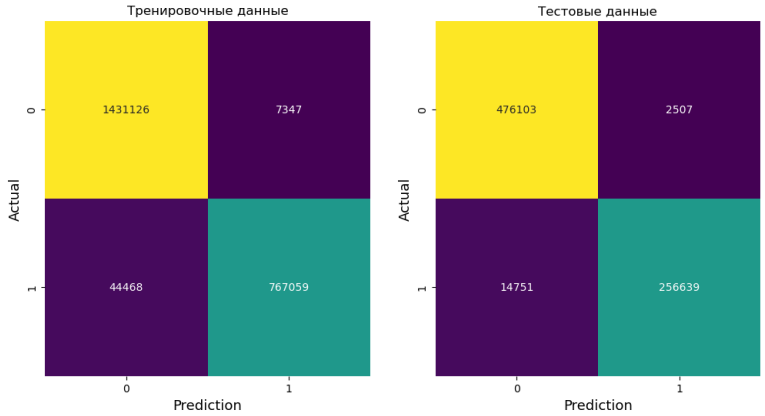

Рисунок 5 – Результаты качества классификации с гиперпараметрами по умолчанию алгоритма *Gradient Boosting*

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

1.1.4 Нейронная сеть

Для классификации клиентов используется однослойная нейронная сеть, состоящая из входного слоя размерности 19 признаков, одного скрытого слоя из 32 нейронов с функцией активации *ReLu* и выходного слоя с функцией *sigmoid*, заложенного в основе формирования вероятности дефолта. Для нейронной сети основными параметрами обучения являются:

1. *epochs* – число эпох обучения нейронной сети. Параметр показывает, сколько раз модель обучается по всей обучающей выборке. Если число эпох слишком мало, то нейронная сеть будет недообучена и неспособна выявить закономерности в данных. В данном случае используется 20 эпох, поскольку является достаточным для обучения модели.

2. $batch_size$ – размер пакета данных, на котором модель обучается за один шаг обучения. Например, $batch_size = 128$ означает, что на одном шаге модель обрабатывает 128 клиентов.
3. $Dense(32)$ – скрытый слой нейронной сети, состоящий из 32 нейронов. Каждый нейрон формирует собственную комбинацию входных признаков, позволяющие модели выявлять скрытые зависимости между характеристиками клиента и вероятностью дефолта.
4. $activation = ReLU$ – функция активации скрытого слоя. Функция $ReLU$ преобразует отрицательные числа в ноль, а положительные значения остаются без изменения, что позволяет алгоритму выявлять наиболее значимые комбинации признаков и создавать более сложные зависимости между входными данными и целевым признаком.
5. $Dense(1)$ – выходной слой, состоящий из одного нейрона. В данной работе решается задача бинарной классификации, поэтому на выходе используется только 1 нейрон, который формирует конечную оценку клиента о принадлежности к классу 0 или 1.
6. $activation = sigmoid$ – функция активации выходного слоя. Сигмоидальная функция преобразует входные значения в диапазон (0; 1) и выводит вероятность дефолта.
7. $optimizer = Adam$ – оптимизатор, с помощью которого нейронная сеть обновляет свои веса в процессе обучения. После каждого шага обучения модель сравнивает свой прогноз с фактическим значением и корректирует веса связей между нейронами.
8. $leraning_rate = 0.005$ – шаг обучения модели.
9. $loss = mse$ – функция потерь, которая показывает насколько прогнозы модели отличаются от фактических значений целевого признака.
10. $BinaryAccuracy$ – метрика точности классификации. Показывает долю верно классифицированных наблюдений. Порог $threshold = 0.5$ означает, что при вероятности выше 0.5 клиент относится к классу дефолтных, а ниже – к классу недефолтных клиентов.

Нейронная сеть показывает высокое качество классификации на обеих выборках (см. Таблицу 8). Метрики $precision$, $recall$, $f1 - score$ показывают хорошее распрзнование недефолтных и дефолтных клиентов. Значения $accuracy = 0.98$ и $ROC - AUC = 0.97$ также свидетельствуют о хорошей разделяющей способности модели. Значения всех метрик практически совпадают, что говорит об отсутствии выраженного эффекта переобучения.

Таблица 8 – Метрики точности Neural Network

Нейронная сеть						
Flag метка	Precision точность	Recall полнота	f1–score f1–мера	Accuracy точность	ROC–AUC	Количество
Тренировочная выборка						
0	0.99	0.97	0.98	0.98	0.97	1438473
1	0.95	0.99	0.97			811527
Тестовая выборка						
0	0.99	0.97	0.98	0.98	0.97	478610
1	0.95	0.99	0.97			271390

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Результаты обучения нейронной сети показывают (см. Рисунок 6) что уже к 5 эпохе точность алгоритма на тренировочной и тестовой выборках (*accuracy*) возрастает, а затем выходит на устойчивый уровень. Параллельно значения функции потерь на обеих выборках снижаются к 5 эпохе и стабилизируются, что также указывает на отсутствие эффекта переобучения.

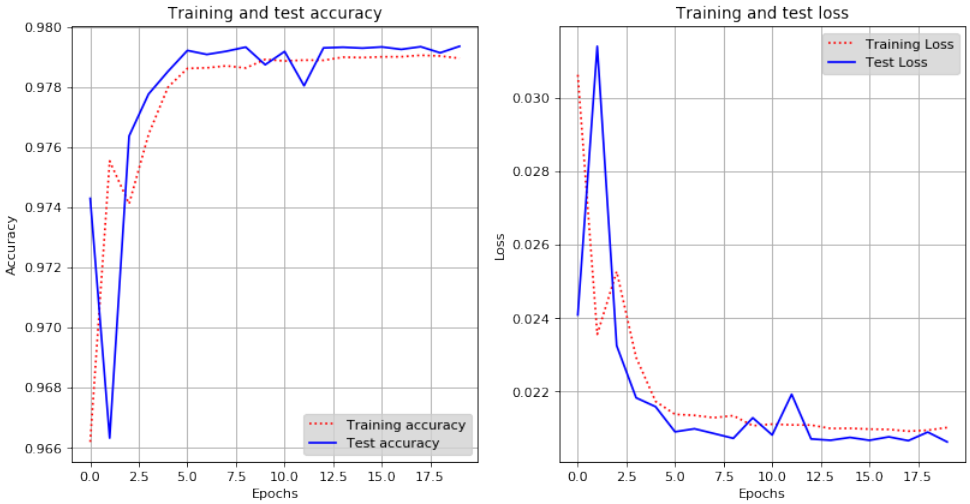

Рисунок 6 – Результаты обучения нейронной сети на тренировочной и тестовой выборках

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

Матрица ошибок (см. Рисунок 7) также подтверждает, что большинство наблюдений в выборках были правильно классифицированы, но можно заметить, что допускает больше ошибочных предсказаний, чем алгоритм дерева решений (*Decision Tree*) и случайного леса (*Random Forest*). При этом соотношение ошибок на обеих выборках остается близким, что указывает на отсутствие эффекта переобучения.

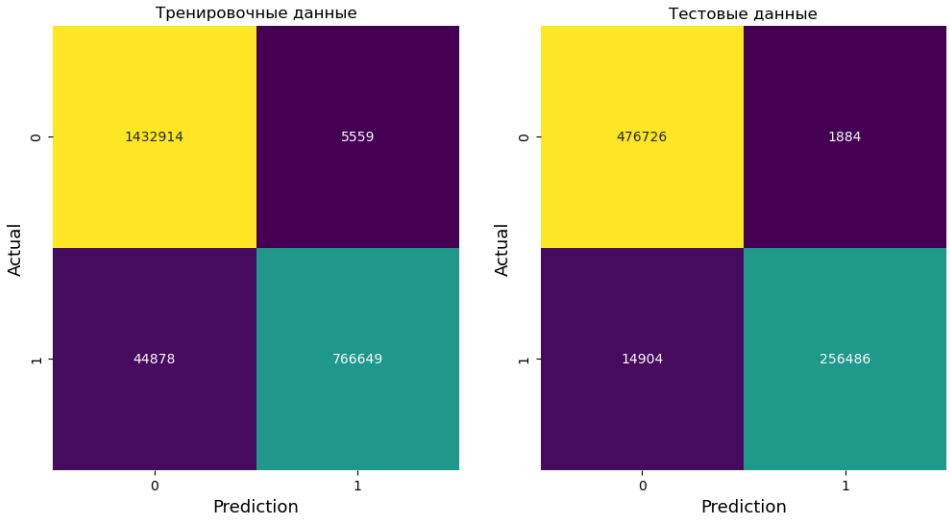

Рисунок 7 – Результаты обучения нейронной сети на тренировочной и тестовой выборке

Источник: составлено автором на основе: Соревнование на данных кредитных историй [Электронный ресурс] / Open Data Science. – URL: https://ods.ai/competitions/dl-fintech-bki (дата обращения: 25.11.2025).

1.2 Ограничения и возможности моделей

На основе проделанной работы в рамках данного датасета можно выделить существенные ограничения и дальнейшие возможности работы моделей при прогнозировании кредитного риска заемщиков. Под ограничениями работы с моделями ИИ понимаются проблемы технического и нормативного характера.

Во-первых, одной из ключевых проблем являются вычислительные ресурсы. Модели дерева решений, случайного леса, градиентного бустинга и нейронной сети требуют значительных вычислительных мощностей при обработке 3 млн данных клиентов банка, что увеличивает длительность обработки на одном алгоритме до нескольких дней. Подбор оптимальных гиперпараметров для улучшения прогностических способностей алгоритмов также может занимать время до недели. Если расширить масштаб анализа на всю банковскую систему Казахстана, где, по данным ПКБ, около 9 млн[6] экономически активного населения имеют кредиты, то требования к вычислительным ресурсам возрастают многократно. Решением может быть либо улучшение IT-инфраструктуры, либо переход на облачные технологии.

Во-вторых, качество работы моделей зависит от экономической среды вместе с которой изменяется и потребительское поведение заемщиков. Поэтому модель, обученная на данных предыдущих периодов, может давать систематические ошибки в прогнозировании дефолта. Следовательно, необходимо регулярно обновлять данные кредитных историй и переобучать модели на обновленных данных.

[6]Свыше 9 млн казахстанцев имеют кредиты на сумму больше 24 трлн тенге [Электронный ресурс] / Информационный канал 24.kz. URL: https://24.kz/ru/news/social/729252-svyshe-9-mln-kazakhstantsev-imeyut-kredity-na-summu-bolshe-kzt24-trln (дата обращения: 6.03.2026).

В-третьих, для качественного прогноза модели помимо кредитных историй можно также анализировать альтернативные данные. Однако доступ к ним ограничен законом о банковской тайне (ст. 53 «О банках и банковской деятельности в Республике Казахстан») и законодательством о персональных данных, которые позволяют использование таких данныъ только с согласия самого клиента. Кроме того, у каждого банка накапливается лишь часть кредитной истории, поскольку кредиты одного заемщика могут быть взяты в разных банках. Поэтому невозможно объединить все кредитные истории со всех банков в единую систему для анализа, т.к. необходимо получить разрешение от всех клиентов. Таким образом, каждый банк вынужден разрабатывать собственные подходы к оценке кредитоспособности заемщиков на основе ограниченного массива доступных банку данных. Создание единой межбанковской системы на основе ИИ, которая могла бы анализировать полную долговую нагрузку клиента, ограничивается правовыми барьерами.

Под возможностями моделей ИИ понимается их предсказательная способность, характеризующаяся метриками точности. Следует отметить, что прогноз модели напрямую зависит от того, насколько корректно определено понятие аномального клиента. Например, в курсовой работе[7], где исследовались данные кредитных историй по Тайваню, метрики точности оказались ниже, чем в данной работе. По этой причине, следует внимательно относиться к предобработке данных, потому что качество их очистки во многом определяет конечный результат прогноза моделей ИИ.

[7] Касенова *А.А.* Определение кредитного скоринга заемщиков банка на основе технологии машинного обучения // Курсовая работа. 2025. С. 1—27.

СПИСОК ЛИТЕРАТУРЫ

1. Ловушка в 20%: почему казахстанцы продолжают кредитоваться при падающих доходах [Электронный ресурс] / Информационный портал РК. — URL: https://www.zakon.kz/finansy/6505800-lovushka-v-20-pochemu-kazakhstantsy-prodolzhayut-kreditovatsya-pri-padayushchikh-dokhodakh.html. — Загл. с экрана.
2. Казахстанцев ждет долговая усталость в 2026 году: экономист озвучил опасения [Электронный ресурс] / Общественно-политическое издание Центральной Азии. — URL: https://kz.kursiv.media/2026-01-27/svan-kazahstancy-prodolzhayut-popolnyat-depozity-i-brat-novye-kredity-nesmotrya-na-stavku/. — Загл. с экрана.
3. Забытые долги казахстанцев перед банками выросли в полтора раза за год [Электронный ресурс] / Общественно-политическое издание Центральной Азии. — URL: https://kz.kursiv.media/2026-03-02/fvfv-zabytyye-dolgi-kazakhstantsev-pered-bankami-vyrosli-v-poltora-raza-za-god/?utm_source=kursiv&utm_campaign=read_more. — Загл. с экрана.
4. GridSearchCV [Электронный ресурс] / Python-библиотека для машинного обучения. — URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GridSearchCV.html. — Загл. с экрана.
5. RandomizedSearchCV [Электронный ресурс] / Python-библиотека для машинного обучения. — URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.RandomizedSearchCV.html. — Загл. с экрана.
6. Свыше 9 млн казахстанцев имеют кредиты на сумму больше 24 трлн тенге [Электронный ресурс] / Информационный канал 24.kz. — URL: https://24.kz/ru/news/social/729252-svyshe-9-mln-kazakhstantsev-imeyut-kredity-na-summu-bolshe-kzt24-trln. — Загл. с экрана.
7. Касенова *А.А.* Определение кредитного скоринга заемщиков банка на основе технологии машинного обучения // Курсовая работа. — 2025. — С. 1—27. — Загл. с экрана.