Результат 1: Обобщено определение кредитного скоринга как ИИ-ориентированного инструмента прогнозирования кредитного риска в банках второго уровня

Таблица 1 – Определение кредитного скоринга в современных практиках

Определение	**Исследователи**
Систематический процесс, оценивающий кредитный риск человека на основе различных финансовых факторов и его поведения из прошлого.	Addy W.A., Ajayi-Nifise A.O., Bello B.G., Tula S.T., Odeyemi O., Falaiye T.
Фундаментальный инструмент финансового принятия решений, который даёт кредитору ключевое понимание риска потенциального заемщика.	Bari H.
Использование искусственного интеллекта и алгоритмов машинного обучения для оценки кредитоспособности на основе нетрадиционных источников данных.	Omotosho M.A.
Процесс количественной оценки кредитоспособности заемщика, при котором прогноз кредитного риска формируется на основе данных о заемщике с использованием моделей машинного обучения.	Vakrani D.S., Padhye P.S., Gupta S.K., Roy J.K., Nerlekar V.S., Parashar N.
Оценка кредитоспособности на основе моделей AI/ML, которые используют расширенный набор данных, включая альтернативные показатели (например, платежи за аренду и коммунальные услуги), чтобы повысить полноту и справедливость оценки.	Nuka T.F., Ogunola A.A.
Это процесс оценки кредитного риска без ручного вмешательства, включающий использование машинного обучения (МО) и аналитики больших данных для анализа огромного массива информации.	Emagia (ведущая американская IT-компания в области интеллектуального управления дебиторской задолженностью на основе искусственного интеллекта по версии The Silicon Review 2025)
Статистический анализ, проводимый финансовыми учреждениями для определения кредитоспособности физических и юридических лиц.	Invento Labs (белорусская IT-компания, специализирующаяся на разработке, внедрении и поддержке программного обеспечения на основе open-source).

Кредитный скоринг – систематический процесс, позволяющий прогнозировать вероятность дефолта заемщика с применением моделей машинного (далее МО) и глубокого (далее ГО) обучения на основе традиционных и альтернативных данных, используемый банками второго уровня при принятии кредитных решений.

1) Под дефолтом понимается неплатежеспособность клиента.

2) Традиционные данные – кредитная история заявителя, которая представляет собой подробный отчёт обо всех предыдущих кредитах и выплатах, включая просроченные платежи и дефолты.
3) Альтернативные данные – счета за коммунальные услуги, арендная плата, информация о банковских счетах и даже активность в социальных сетях, что даёт более полное представление об экономическом поведении соискателя.

Результат 2: Систематизированы основные направления применения ИИ в банковском секторе

Направления применения ИИ в банковском секторе	Содержание направления	Реализация на практике и результаты	Преимущества направления	Источники направлений
1.Чат-боты и робоконсультации	Автоматизация консультаций, круглосуточная поддержка, обработка жалоб или обращений	**State Bank of India (SIA):** обработка до **10 000 запросов/сек**, масштабирование поддержки при высокой нагрузке. **Bank of America (Erica):** с момента запуска сервисом воспользовались **>32 млн клиентов** (отчёт, октябрь 2022). **Тинькофф-банк:** экономия **30–200 млн руб./мес**, **>40%** клиентов удовлетворяются ответом бота; средняя консультация быстрее примерно на **40 секунд**.	1. Снижение операционных затрат на обслуживание клиентов (частичная замена операторов). 2. Сокращение времени на реагирование и обработку запросов. 3. Круглосуточная доступность поддержки. 4. Стандартизация качества консультаций, что снижает влияние человеческого фактора.	В.С. Балаян, И. Романович, А. Герасимович, А. Вабищевич, О.Ю. Городецкая, Я.Л. Гобарева, Э.А. Гозгешев, В.Л. Пархоменко, И.С. Кулаева, НБРК
2.Персонализация финансовых продуктов	Индивидуальные предложения финансовых продуктов или услуг	**Тинькофф-банк:** рекомендательные модели формируют **персональные предложения** на основе поведения клиента (например, напоминания о регулярных покупках, подсказки по операциям и действиям в приложении).	1. Повышение релевантности предложений за счет анализа предпочтений и поведения клиентов. 2. Рост удержания клиентов через персонализированные услуги. 3. Улучшение клиентского опыта благодаря персонализации.	В.С. Балаян, О.Ю. Городецкая, Я.Л. Гобарева, Э.А. Гозгешев, НБРК
3.Антифрод	Выявление аномальных финансовых операций, предупреждение мошенничества	**JPMorgan Chase:** применение ML-предиктивной аналитики для выявления мошенничества **в реальном времени**; снижение ущерба, по оценкам, **>100 млн долл. США/год**. **Антифрод-центр НБ РК:** за **6 месяцев** зарегистрировано **17 802** инцидента; заблокировано около **1,5 млрд тенге**, что позволило снизить ущерб от мошенничества.	1. Снижение финансовых потерь от мошенничества за счет раннего выявления подозрительных операций. 2. Обнаружение аномалий в режиме реального времени, быстрая реакция на блокировку транзакций.	О.Ю. Городецкая, Я.Л. Гобарева, Э.А. Гозгешев, В.Л. Пархоменко, И.С. Кулаева, Д.И. Михайлов, N. Mehndiratta, G. Arora, R. Bathla, НБРК

			3. Усиление доверия к банковским сервисам за счет повышения безопасности.	
4.**Кредитный скоринг**	Оценка кредитоспособности заемщиков банка, прогноз вероятности дефолта, автоматизация одобрения или отказа в кредите	**Tonik (Philippines):** модель **FinScore** оценивает клиентов без кредитной истории на основе телеком-данных (около **400 параметров**), расширяя доступ к кредитованию. **WeBank (China):** применяет ИИ и данные экосистемы **Tencent/WeChat** для оценки кредитного риска и выдачи кредитов МСБ с ограниченной историей; интеграция поведенческих и транзакционных данных поддерживает персонализированный скоринг. **Zest AI (USA):** AI-скоринг повышает долю одобрений на **20–30%** при сопоставимом уровне риска; решения используются более чем в **180** банках и кредитных союзах. **ВТБ:** применение ИИ привело к росту выдачи розничных кредитов примерно на **20%**.	1. Повышение точности прогнозирования дефолта. 2. Быстрое принятие кредитных решений за счет автоматизации. 3. Расширение финансовой доступности для клиентов без кредитной истории через альтернативные данные. 4. Снижение кредитных потерь за счет более точной оценки риска.	О.Ю. Городецкая, Я.Л. Гобарева, Э.А. Гозгешев, В.Л. Пархоменко, И.С. Кулаева, Д.И. Михайлов, N. Mehndiratta, G. Arora, R. Bathla, НБРК

Результат 3: Систематизированы основные данные о заемщиках для кредитного скоринга: традиционные и альтернативные признаки

Традиционные признаки	Альтернативные признаки (применение ИИ)
Кредитная история: наличие/частота просрочек, история погашений	**Оплата за аренду жилья**: регулярность и своевременность оплат
Доход и занятость: уровень дохода и стаж/стабильность занятости	**Коммунальные платежи**: регулярность и своевременность оплат
Долговая нагрузка: наличие действующих обязательств	**Безналичные платежи и переводы:** операции в электронных кошельках/мобильных платежных сервисах

Социально-демографические признаки: пол, возраст, регион, семейное положение	Телеком-данные (редко): пополнение, использование мобильного интернета
Параметры кредита: сумма кредита, срок, размер ежемесячного платежа	**Цифровые следы (ограничения с этикой и приватностью):** социальные сети

Результат 4: Сопоставление традиционного и современного подходов к оценке платежеспособности заемщика

Критерий сравнения	**Традиционные модели**	**Современные модели**	**Источники**
Тип моделей	Логистическая регрессия, деревья решений	Случайный лес, градиентный бустинг, нейронные сети	Vakrani D.S. и соавт. (2026); Addy W.A. и соавт. (2024)
Данные для оценки	Традиционные: кредитная история, доход, занятость и т.д.	Традиционные и альтернативные: аренда, коммунальные платежи, мобильные транзакции и т.д.	Vakrani D.S. и соавт. (2026); Kothandapani P., Hariharan H. (2022); Nuka T.F., Ogunola A.A. (2024)
Охват клиентов	Клиенты с емкой кредитной историей. С тонкой или отсутствующей историей хуже оценивает	Наиболее инклюзивны за счет альтернативных данных и моделей, которые могут выявлять сложные закономерности	Kothandapani P., Hariharan H. (2022); Nuka T.F., Ogunola A.A. (2024); Addy W.A. и соавт. (2024)
Адаптивность	Статичны, хуже подстраиваются под изменения	Динамичны, подстраиваются под обновление данных	Addy W.A. и соавт. (2024); Vakrani D.S. и соавт. (2026)
Интерпретируемость	Проще объяснить решение	Проблема «черного ящика», т.е. возникают	Vakrani D.S. и соавт. (2026); Nuka T.F.,

		сложности при интерпретации	Ogunola A.A. (2024)
Устойчивость при стресс-тестировании	Точность логистической регрессии снизилось с 0.76 до 0.68. Метрика ROC-AUC с 0.76 до 0.68	Точность остается наиболее стабильной. Метрика ROC-AUC с 0.89 до 0.83.	Vakrani D.S. и соавт. (2026)
Ограничения	Недостаточно данных для оценки дефолта новых клиентов, слабо выявляют нелинейные связи	Требования к высокой обеспеченности конфиденциальных данных, необходимость регулярного мониторинга моделей	Nuka T.F., Ogunola A.A. (2024); Addy W.A. и соавт. (2024)

В исследовании **Vakrani D.S.** было проведено моделирование макроэкономического стресс-сценария, предполагающего снижение среднего дохода заемщиков на **20%** и рост вероятности дефолта на **15%**.

Целью анализа было оценить устойчивость традиционных и ИИ-ориентированных моделей в условиях ухудшения макроэкономической среды.

Полученные результаты:

1. Логистическая регрессия (традиционная модель):

- До стресс-сценария: **ROC-AUC = 0,76**
- После стресс-сценария: **ROC-AUC = 0,68**
- Снижение: **–0,08**

Качество модели заметно ухудшилось, что свидетельствует о более высокой чувствительности к изменению внешних экономических условий.

2. XGBoost (ИИ-модель):

- До стресс-сценария: **ROC-AUC = 0,89**
- После стресс-сценария: **ROC-AUC = 0,83**
- Снижение: **–0,06**

Несмотря на ухудшение макроэкономических условий, модель продемонстрировала более устойчивое качество прогнозирования.